

SCAYL - Herramientas de IA utilizadas

hackIAthon Panamá 2026 · TVN Media · De la señal a la decisión
Equipo: Silentarcherjr, frictionspp-svg y LowCrime
Actualizado al cierre del 8 de octubre de 2026, hora de Panamá.

La IA apoyó el desarrollo y la preparación de borradores. El equipo humano definió el alcance, autorizó las integraciones y conservó la decisión editorial. Los resultados se presentan con su método de evaluación y alcance.

1. Herramientas de desarrollo

Herramienta	Propósito	Aplicación concreta	Resultado	Intervención humana
Claude Code (Anthropic), rol de Lead técnico	Análisis del reto, arquitectura, núcleo de evidencia y generación, revisión e integración	Lectura de los PDF oficiales y aclaraciones; contratos Pydantic; puntaje, estado de evidencia, Source DNA, Temporal Guard, conflictos, validadores, plantilla, Story Studio, consultas con abstención, defensa contra inyección; revisión de PR de los demás agentes; páginas de documentación	scayl/ (contratos, evidencia, generación, revisión, pipeline); suite de pruebas en verde en cada merge	Silentarcherjr dirigió, revisó y aprobó cada PR; decisiones registradas en el decision log
Claude Code + búsqueda web	Estado del arte y verificación técnica	Revisión de herramientas y artículos de verificación, límites de la API GDELT y modelos locales para 8 GB de VRAM	Sección de revisión del plan y decisiones DL-006/008/009	Fuentes enlazadas y decisión del equipo
Codex (OpenAI)	Adquisición de datos, interfaz, evaluación, web Next.js	Fetchers GDELT DOC/GKG, RSS TVN, World Bank y USGS con manifest SHA-256; Streamlit (Sala, Ficha, Consultas, Agenda, Trust Lab); exportador público y web Next.js estática; runner de red-team; preparación de muestras para revisión humana	Snapshot de 187 noticias (50 TVN), 540 observaciones WB y eventos USGS; web publicada en Vercel	frictionspp-svg y LowCrime operaron sus agentes; el Lead revisó y mergeó; Codex no generó etiquetas humanas ni tiempos
Claude Code (subagentes coordinados)	Mejoras finales y auditoría de cierre (2026-10-08)	Subagentes aislados para validadores de generación, recuperación de consultas, contradicciones/evidencia, experiencia de usuario y auditoría de QA/seguridad	Solo se integró lo que pasó pruebas y revisión del Lead	Aprobación humana de push, PR y acciones externas
Playwright + Chromium (automatización, no IA generativa)	Capturas reproducibles y video	Capturas de pantalla reales de la aplicación y grabación del recorrido del anuncio	Imágenes de documentación sin edición generativa	Inspección visual por el equipo
Síntesis y transcripción de voz (pipeline tools/ad/)	Narración del anuncio en video	Voz generada con el motor TTS configurado en tools/ad/voice.py (edge-tts o Kokoro); transcripción opcional con faster-whisper para revisar que la voz se entienda; música generada por código	Producción de material audiovisual de demostración; no forma parte del motor editorial	Guion escrito y revisado por el equipo; cada cifra narrada proviene de eval/results/
Codex (GPT-6), tres subagentes	Auditoría final y cierre de entrega	Verificación técnica, verificador determinista, pruebas CI, entrega administrativa, corrección de documentación y publicación de cuatro páginas propias en Notion	442 pruebas automatizadas aprobadas; validación técnica de la aplicación y documentación de entrega actualizada	Revisión del equipo y autorización humana de integraciones y publicación

2. IA dentro del producto

Componente	Modelo	Uso	Resultado medido y límites
LLM local	Qwen3 8B (Q4_K_M) vía Ollama, ejecución local	Extracción de afirmaciones y paquete editorial (Story Studio) con citas obligatorias por oración; validadores deterministas descartan oraciones sin respaldo y vuelven a la plantilla	Precálculo top 15: 15/15 generados en vivo, 0 fallback, 45/45 oraciones con cita (cobertura, no validez); mediana 13,1 s por paquete en GPU AMD RX 9060 XT. La web pública sirve esas salidas desde caché, no inferencia en vivo. Cierre adicional en M1 Max: 30/30 paquetes en vivo, mediana 19,5 s, p95 37,2 s; agrupación TF-IDF distinta del bundle publicado. Sustento de Qwen no medido hasta revisión humana
Embeddings	E5 multilingüe (local, CPU)	Agrupación de noticias en eventos; recuperación híbrida experimental	F1 de agrupación 0,99 en pares de desarrollo usados para calibrar (optimista, no independiente)
Modo plantilla	Sin modelo (determinista)	Respaldo seguro cuando el modelo falla o no está disponible	Sustento revisado por una persona: 25/30 afirmaciones (modo plantilla)
Consultas	BM25 (sin LLM en la ruta principal)	Respuesta extractiva citada o abstención explícita	Abstención correcta 6/6 en un conjunto escrito por una persona; 16/16 en un set sintético de desarrollo
Consultas · IA generativa en vivo (opcional)	Gemini 3.5 Flash-Lite (Google, API externa opcional)	Modo elegido por el usuario en Consultas. Solo se envían la pregunta y hasta 8 extractos de evidencia pública; no se llama al proveedor si SCAYL se abstiene antes (sin evidencia, cifra falsa o inyección). La respuesta pasa por los mismos validadores de citas y cifras; ante fallo o cuota agotada, respuesta con evidencia como fallback visible	Pruebas reales locales y en Preview, con latencias registradas de aproximadamente 0,8 a 1,3 s del proveedor. La disponibilidad, cuota y costo dependen del proyecto de Google. Estas pruebas no constituyen una métrica de exactitud
Verificador de afirmaciones	Sin modelo (BM25 + reglas)	Contrasta una afirmación con el snapshot: cifra, período, país y unidad; nunca declara verdadero o falso	Comparación de indicador, cifra, período, país y unidad; diez regresiones automatizadas y siete comprobaciones reales en la aplicación publicada. Es determinista: no usa IA generativa ni declara verdad

Costo: Qwen local no genera cargos de API; hardware, electricidad y mantenimiento están excluidos y no medidos. Gemini es externo: cuota y costo sujetos al proyecto de Google. Costo global no medido. En el nivel gratuito, Google puede usar las solicitudes para mejorar sus productos; solo se envían la pregunta y extractos públicos.

3. Resultados y alcance de la evaluación

- Validación técnica final: 442 pruebas automatizadas aprobadas; Ruff, lint y build correctos. Siete comprobaciones reales del verificador en la aplicación publicada.
- La cobertura de citas de 45/45 mide presencia de referencias. La revisión humana de sustento de 25/30 corresponde a paquetes en modo plantilla y no se extrapola a las salidas de Qwen.
- La agrupación se evaluó en pares de desarrollo usados para calibrar. $\text{Precision@5} = 1/5$ es exploratoria, frente a una selección de un integrante.
- Los conjuntos sintéticos y escritos por IA se distinguen de las evaluaciones con etiquetas humanas. No se presentan como un conjunto editorial independiente.
- El valor operativo se plantea como hipótesis; no se afirma ahorro de tiempo sin un estudio comparativo.

Uso responsable

La aplicación identifica el modo de cada salida: IA local guardada, plantilla o Gemini externo. La prioridad mide atención; una persona conserva la decisión de revisión y publicación.

Los textos se construyen con evidencia del corpus y citas. El sistema se abstiene cuando falta sustento; la validación automática apoya la revisión editorial y no la sustituye.

Trazabilidad

Registro completo de herramientas: docs/AI_TOOLS_USED.md. Resultados y métodos: eval/results/ y documentación técnica del proyecto.

Aplicación: <https://scayl-editorial.vercel.app/>

Repositorio: <https://github.com/Silentarcherjr/scayl-sala-de-inteligencia-editorial>